



INFORME DE LA APLICACIÓN

INTELIGENCIA ARTIFICIAL (ASIo4o4)

TRABAJO FINAL

Nombre del proyecto:

Predicción de Adicción al Teléfono Inteligente en Adolescentes mediante Redes Neuronales
Artificiales

Presentado por:

Almeida Aguilar, Ivan Antonio

2026

1. Descripción del problema	3
2. Descripción del conjunto de datos	4
2.1 Visualización de datos	5
3. Propuesta	8
4. Diseño del aplicativo	9
5. Validación de resultados y pruebas	10
5.1 Clasificación binaria y matriz de confusión	12
5.2 Comparación con un modelo de Regresión Lineal	14
6. Consideraciones éticas	16
7. Conclusiones	17
8. Referencias bibliográficas	19
9. Anexos	21
Anexo A: Repositorio del proyecto	21

1. Descripción del problema

La adicción al teléfono inteligente se ha consolidado como un problema de salud pública en los últimos años, especialmente entre la población adolescente. Según estudios recientes (Pew Research Center, 2022), más del 45 % de los adolescentes estadounidenses reportan estar "casi constantemente" en línea, y una proporción importante presenta síntomas de dependencia conductual, como ansiedad al no disponer del dispositivo, disminución del rendimiento académico y alteraciones del sueño.

Diversas investigaciones recientes han profundizado en este fenómeno y muestran que el uso problemático del teléfono inteligente está asociado con conflictos en las relaciones sociales y alteraciones en los sistemas de recompensa cerebral (Aguirre-Peñañiel & Matar-Khalil, 2025). Asimismo, estudios con muestras representativas a nivel nacional en China, como el de Liu et al. (2026), confirman la magnitud del problema y destacan la heterogeneidad de los factores que influyen en la adicción. En la misma línea, Li et al. (2025) emplearon técnicas de aprendizaje automático y análisis de redes para identificar que la ansiedad, la rumiación y las estrategias de afrontamiento emocional constituyen algunos de los factores más relevantes asociados a la adicción al smartphone en adolescentes de secundaria.

La heterogeneidad de estos factores hace que los enfoques tradicionales, basados únicamente en encuestas subjetivas, resulten limitados para identificar a los adolescentes con mayor riesgo de desarrollar una dependencia problemática. En este contexto, las técnicas de aprendizaje automático representan una alternativa prometedora para modelar las relaciones complejas entre los múltiples factores asociados al uso del teléfono inteligente, permitiendo desarrollar herramientas de apoyo para la detección temprana y la toma de decisiones.

En este trabajo se propone un modelo capaz de predecir el nivel de adicción al teléfono inteligente, medido en una escala de 0 a 10, a partir de variables demográficas, conductuales y psicosociales, entre ellas las horas de uso diario, el tiempo dedicado a redes sociales, la frecuencia de revisión del teléfono, las horas de sueño y el nivel de ansiedad. Para ello, se desarrolla una Red Neuronal Artificial (RNA) de tipo **Multilayer Perceptron (MLP)**, capaz de estimar de manera automatizada el nivel de adicción y servir como herramienta de apoyo para padres, educadores y profesionales de la salud en la identificación temprana de adolescentes con mayor riesgo.

2. Descripción del conjunto de datos

El conjunto de datos utilizado en este trabajo corresponde a **Teen Phone Addiction and Lifestyle Survey**, disponible públicamente en la plataforma Kaggle. Este dataset fue recopilado mediante encuestas aplicadas a **3,000 adolescentes** de entre **13 y 18 años**, provenientes de distintas ubicaciones geográficas, con el propósito de analizar la relación entre los hábitos de uso del teléfono inteligente, factores psicosociales y el nivel de adicción.

El conjunto de datos contiene **25 variables**, las cuales pueden agruparse en tres categorías principales:


- ❖ **Variables demográficas:** ID, Name, Age, Gender, Location y School_Grade.
- ❖ **Hábitos de uso del teléfono:** Daily_Usage_Hours, Weekend_Usage_Hours, Time_on_Social_Media, Time_on_Gaming, Time_on_Education, Apps_Used_Daily, Phone_Checks_Per_Day, Screen_Time_Before_Bed y Phone_Usage_Purpose.
- ❖ **Variables psicosociales:** Sleep_Hours, Academic_Performance, Social_Interactions, Exercise_Hours, Anxiety_Level, Depression_Level, Self_Esteem, Parental_Control y Family_Communication.

La variable objetivo del modelo es **Addiction_Level**, una variable continua con valores comprendidos entre **0 y 10**, donde **0** representa ausencia de adicción y **10** el nivel máximo de dependencia al teléfono inteligente.

Como parte del preprocesamiento, se eliminaron las variables **ID**, **Name** y **Location**, debido a que no aportan información relevante para la predicción y podrían introducir ruido en el entrenamiento del modelo. Posteriormente, las variables categóricas (**Gender**, **School_Grade** y **Phone_Usage_Purpose**) fueron transformadas mediante **One-Hot Encoding**, generando variables binarias independientes que evitan introducir relaciones ordinales inexistentes y resultan adecuadas para el entrenamiento de una Red Neuronal Artificial. Asimismo, las variables numéricas fueron estandarizadas utilizando **StandardScaler**, con el fin de que todas presentaran una escala comparable y facilitaran el proceso de optimización del modelo.

2.1 Visualización de datos

Figura 1. Matriz de correlación de Pearson entre variables predictoras y *Addiction_Level*.



Con el propósito de comprender la estructura del conjunto de datos e identificar las variables con mayor capacidad predictiva, se realizó un análisis exploratorio mediante una matriz de correlación de Pearson.


Los resultados muestran que **Daily_Usage_Hours** presenta la correlación positiva más alta con **Addiction_Level** ($r = 0.60$), seguida por **Apps_Used_Daily** ($r = 0.32$), **Time_on_Social_Media** ($r = 0.31$), **Time_on_Gaming** ($r = 0.27$) y **Phone_Checks_Per_Day** ($r = 0.25$). Estas variables representan los principales indicadores del uso intensivo del teléfono inteligente y constituyen los predictores más relevantes del modelo.

En contraste, **Sleep_Hours** presenta una correlación negativa moderada ($r = -0.22$), lo que sugiere que un mayor número de horas de sueño se asocia con menores niveles de adicción. Por otro lado, variables como la edad, la ansiedad, la depresión, el rendimiento académico y el tiempo de pantalla antes de dormir muestran correlaciones lineales cercanas a cero, indicando una menor relación lineal con la variable objetivo dentro de este conjunto de datos.

Asimismo, las correlaciones entre las variables predictoras son, en su mayoría, reducidas, lo que indica una baja presencia de multicolinealidad y sugiere que cada característica aporta información complementaria al proceso de aprendizaje del modelo.

Los resultados obtenidos justifican la selección de las variables con mayor correlación como elementos principales de la interfaz de predicción, mientras que las variables con menor influencia se incorporan como parámetros opcionales para complementar la estimación cuando dicha información se encuentra disponible.

Figura 2. Distribución de frecuencia del nivel de adicción en adolescentes.




La Figura 2 muestra la distribución de la variable objetivo **Addiction_Level**. Se observa una distribución asimétrica, concentrada en los niveles más altos de adicción, donde el valor **10** representa más del **50 %** de los registros del conjunto de datos.

Por el contrario, los niveles bajos de adicción presentan una frecuencia considerablemente menor, lo que evidencia un desbalance en la distribución de la variable objetivo.

Esta característica del conjunto de datos tiene implicaciones directas en el entrenamiento del modelo, ya que una gran proporción de los ejemplos pertenece a una misma región del espacio de salida. En consecuencia, además del coeficiente de determinación (R^2), se empleó el **Error Absoluto Medio (MAE)** como métrica principal de evaluación, debido a que proporciona una medida fácilmente interpretable del error promedio y resulta menos sensible a valores extremos que otras métricas como el RMSE.

Figura 3. Boxplots de variables clave según categoría de adicción.



La Figura 3 presenta diagramas de caja para las cinco variables con mayor correlación respecto a **Addiction_Level**, agrupadas según las categorías de adicción (Muy Baja, Baja, Moderada y Alta).

Los diagramas muestran diferencias consistentes entre los distintos grupos. En particular, **Daily_Usage_Hours** presenta un incremento progresivo conforme aumenta el nivel de adicción, observándose una mediana cercana a **5.5 horas diarias** en el grupo de adicción alta frente a aproximadamente **1.4 horas** en el grupo de adicción muy baja.

Un comportamiento similar se aprecia en **Time_on_Social_Media** y **Phone_Checks_Per_Day**, donde los adolescentes con mayores niveles de adicción dedican más tiempo a las redes sociales y revisan con mayor frecuencia su teléfono inteligente. En contraste, **Sleep_Hours** mantiene una tendencia inversa, registrando menores valores en los grupos con mayor nivel de dependencia.

Estas visualizaciones complementan el análisis de correlación al mostrar que las diferencias entre categorías no solo son estadísticamente consistentes, sino también fácilmente interpretables desde una perspectiva práctica. En conjunto, el análisis exploratorio confirma que las variables seleccionadas constituyen una base adecuada para el entrenamiento del modelo de predicción propuesto.

3. Propuesta

El presente trabajo propone el desarrollo de un sistema de predicción del nivel de adicción al teléfono inteligente mediante una **Red Neuronal Artificial (RNA)** de tipo *Multilayer Perceptron* (MLP) orientada a problemas de regresión. El objetivo es estimar automáticamente el nivel de adicción de un adolescente a partir de variables demográficas, conductuales y psicosociales, proporcionando una herramienta de apoyo para la detección temprana y la toma de decisiones en contextos educativos y de salud.

La elección de una RNA tipo MLP se fundamenta tanto en sus características técnicas como en la evidencia reportada en la literatura reciente. Diversos estudios han empleado con éxito este tipo de arquitectura para predecir la adicción al smartphone en poblaciones adolescentes. Kim et al. (2024), por ejemplo, utilizaron un MLP y una red neuronal convolucional (CNN) para realizar predicciones explicables del uso problemático del teléfono inteligente en niños y adolescentes de Corea del Sur, demostrando la eficacia de las redes neuronales en este dominio. De manera similar, investigaciones que comparan múltiples algoritmos supervisados, entre ellos redes neuronales, árboles de decisión y métodos de *ensemble*, concluyen que los modelos neuronales alcanzan una elevada precisión en la predicción de los niveles de dependencia, superando a enfoques lineales tradicionales (K. S. et al., 2025). Estos antecedentes respaldan la selección de una arquitectura MLP para este proyecto.

La arquitectura propuesta corresponde a un perceptrón multicapa compuesto por **dos capas ocultas de 100 y 50 neuronas**, respectivamente. Esta configuración permite modelar relaciones complejas entre las variables de entrada y reducir progresivamente la dimensionalidad de la representación interna antes de generar la predicción final. Se utilizó la función de activación **ReLU** debido a su eficiencia computacional y a su capacidad para mitigar el problema del desvanecimiento del gradiente durante el entrenamiento. Como algoritmo de optimización se empleó **Adam**, el cual ajusta automáticamente la tasa de aprendizaje y favorece una convergencia más rápida y estable.

El entrenamiento del modelo se realizó durante **500 épocas**, valor seleccionado tras observar que el error de validación se estabilizaba a partir de ese punto. Además, se incorporó regularización **L2** ($\alpha = 0.001$) con el propósito de reducir el riesgo de sobreajuste y mejorar la capacidad de generalización del modelo sobre datos no utilizados durante el entrenamiento.

La metodología seguida corresponde al flujo habitual de un proyecto de ciencia de datos. En primer lugar, se realizó la recolección y limpieza del conjunto de datos, seguida de un análisis exploratorio (EDA) para identificar patrones y relaciones entre las variables. Posteriormente, las variables categóricas fueron transformadas mediante **One-Hot Encoding**, mientras que las variables numéricas fueron estandarizadas utilizando **StandardScaler**. El conjunto de datos se dividió en un **80 % para entrenamiento** y un **20 % para prueba**, garantizando una evaluación independiente del modelo.


Una vez finalizado el preprocesamiento, se entrenó el modelo **MLPRegressor** utilizando la arquitectura previamente descrita y se evaluó su desempeño mediante el **Coefficiente de Determinación (R^2)** y el **Error Absoluto Medio (MAE)**, métricas ampliamente utilizadas para valorar modelos de regresión.

Como etapa final, el modelo entrenado fue integrado en una interfaz web desarrollada con **Gradio**, permitiendo a los usuarios ingresar los valores de las variables predictoras y obtener en tiempo real una estimación del nivel de adicción al teléfono inteligente. De esta manera, la solución propuesta no solo demuestra la viabilidad del modelo desde el punto de vista técnico, sino que también facilita su utilización como herramienta de apoyo para la detección temprana y la toma de decisiones.

4. Diseño del aplicativo

El aplicativo fue diseñado siguiendo una arquitectura modular que separa claramente las etapas de preprocesamiento de datos, entrenamiento del modelo e interacción con el usuario. Esta organización facilita el mantenimiento del código, permite reemplazar o actualizar cada componente de manera independiente y favorece la reutilización del modelo en futuras versiones del sistema.

Figura 4. Diagrama de flujo del sistema



El funcionamiento general del aplicativo sigue el flujo mostrado en la **Figura 4**. En primer lugar, el usuario ingresa los valores de las variables predictoras mediante una interfaz web. Posteriormente, estos datos son sometidos al mismo proceso de preprocesamiento aplicado durante el entrenamiento del modelo, que incluye la codificación de las variables categóricas mediante **One-Hot Encoding** y la estandarización de las variables numéricas utilizando **StandardScaler**. Una vez transformados, los datos son enviados a la Red Neuronal Artificial, la cual genera una estimación del nivel de adicción al teléfono inteligente. Finalmente, el sistema presenta la predicción al usuario junto con una interpretación cualitativa del nivel de riesgo.

La interfaz se organizó en dos secciones con el propósito de facilitar su utilización y reducir la cantidad de información que el usuario debe ingresar.

- ❖ **Sección principal:** incluye las seis variables con mayor capacidad predictiva identificadas durante el análisis exploratorio (**Daily_Usage_Hours**, **Apps_Used_Daily**, **Time_on_Social_Media**, **Time_on_Gaming**, **Phone_Checks_Per_Day** y **Sleep_Hours**). Estas variables constituyen la información mínima necesaria para realizar una estimación confiable del nivel de adicción.
- ❖ **Sección avanzada (opcional):** incorpora el resto de las variables demográficas y psicosociales consideradas por el modelo, como la edad, el género, el nivel de ansiedad, la autoestima o el control parental. Cuando el usuario desconoce alguno de estos valores, la aplicación emplea valores de referencia obtenidos del conjunto de datos para completar la información requerida sin interrumpir el proceso de predicción.

El sistema fue desarrollado en **Python**, empleando **scikit-learn** para la implementación de la Red Neuronal Artificial (**MLPRegressor**), **pandas** para la manipulación del conjunto de datos, **NumPy** para las operaciones numéricas y **Gradio** para el desarrollo de la interfaz web. La aplicación fue diseñada para ejecutarse en cualquier entorno compatible con **Python 3.14** o superior, facilitando su instalación y posterior despliegue.

5. Validación de resultados y pruebas

El modelo fue evaluado utilizando el **20 %** del conjunto de datos reservado para prueba, correspondiente a **600 registros**. Para medir su desempeño se emplearon dos métricas ampliamente utilizadas en problemas de regresión: el **Coefficiente de Determinación (R^2)** y el **Error Absoluto Medio (MAE)**.

Las métricas obtenidas fueron las siguientes:

- ❖ **Coefficiente de determinación (R^2): 0.987**
- ❖ **Error Absoluto Medio (MAE): 0.146**

Estos resultados indican que el modelo explica una proporción muy alta de la variabilidad observada en el nivel de adicción y realiza predicciones con un error promedio inferior a dos décimas de punto en una escala de 0 a 10.

El elevado valor de R^2 puede atribuirse, en parte, a las características del conjunto de datos utilizado. La variable objetivo (**Addiction_Level**) presenta una fuerte relación con variables como **Daily_Usage_Hours**, **Time_on_Social_Media** y **Apps_Used_Daily**, las cuales mostraron las correlaciones más altas durante el análisis exploratorio. Asimismo, más del **50 %** de los registros corresponde al valor máximo de la variable objetivo, reduciendo la variabilidad de una parte importante del conjunto de datos y contribuyendo al elevado desempeño observado.

Por otra parte, la separación entre los conjuntos de entrenamiento y prueba, junto con la aplicación de regularización **L2** ($\alpha = 0.001$), contribuye a disminuir el riesgo de sobreajuste

y favorece la capacidad de generalización del modelo. El bajo valor obtenido para el **MAE** respalda que las predicciones mantienen un nivel de error reducido sobre datos no utilizados durante el entrenamiento.

Como validación cualitativa, se realizaron pruebas adicionales mediante la interfaz desarrollada en **Gradio**. En un primer caso, un adolescente con **8 horas** de uso diario del teléfono, **150 revisiones** al día y **4 horas** de uso de redes sociales obtuvo una estimación de **9.8**, correspondiente a un nivel alto de adicción. En un segundo caso, un adolescente con **2 horas** de uso diario, **20 revisiones** del teléfono y **7 horas** de sueño obtuvo una estimación de **5.3**, correspondiente a un nivel considerablemente menor de adicción. Ambos resultados son coherentes con el comportamiento esperado y muestran que el modelo responde adecuadamente a variaciones en las variables de entrada.

Los resultados obtenidos son consistentes con investigaciones recientes sobre la predicción de la adicción al smartphone mediante técnicas de aprendizaje automático. En particular, Li et al. (2025) identifican la ansiedad y el afrontamiento emocional como factores centrales asociados a esta problemática, mientras que Liu et al. (2026) destacan la importancia de variables relacionadas con la intensidad de uso del teléfono inteligente, coincidiendo con las altas correlaciones observadas para **Daily_Usage_Hours** y **Time_on_Social_Media** en este estudio.

Asimismo, la incorporación del nivel de ansiedad como variable predictora responde a la evidencia presentada por Zhou et al. (2025), quienes señalan que factores psicosociales como la rumiación y el acoso escolar constituyen predictores relevantes en adolescentes. De igual manera, la variable objetivo utilizada en este trabajo se fundamenta en instrumentos validados como la **Smartphone Addiction Scale–Short Version (SAS-SV)**, cuyas propiedades psicométricas han sido confirmadas en población hispanohablante (Hidalgo-Fuentes et al., 2025), aportando solidez a la medición del nivel de adicción. En conjunto, el elevado valor de **R²** y el bajo **MAE** obtenidos son coherentes con el desempeño reportado por estudios recientes que comparan múltiples modelos de aprendizaje automático para esta misma problemática (K. S. et al., 2025).

Como principal limitación, el modelo depende de la calidad y consistencia de los datos proporcionados por el usuario. La presencia de valores atípicos, inconsistentes o fuera del rango observado durante el entrenamiento puede afectar la precisión de las predicciones. Además, el modelo fue entrenado utilizando un único conjunto de datos obtenido mediante encuestas, por lo que su capacidad de generalización a otras poblaciones, contextos culturales o grupos etarios deberá evaluarse mediante estudios adicionales.


No obstante, el preprocesamiento de los datos mediante **One-Hot Encoding**, la estandarización de las variables numéricas con **StandardScaler** y la incorporación de regularización **L2** contribuyen a mejorar la estabilidad del modelo y su capacidad para generar predicciones consistentes frente a nuevos casos. En conjunto, los resultados obtenidos muestran

que la Red Neuronal Artificial propuesta constituye una herramienta viable para estimar el nivel de adicción al teléfono inteligente dentro de las características y limitaciones del conjunto de datos utilizado.

5.1 Clasificación binaria y matriz de confusión

Si bien el modelo fue diseñado como un problema de regresión, resulta útil evaluar su desempeño desde una perspectiva de clasificación, dado que en la práctica el objetivo suele ser identificar si un adolescente se encuentra o no en riesgo de adicción. Para ello, se definió un umbral de **6.0** sobre la variable **Addiction_Level**, de manera que los valores iguales o superiores se clasifican como "**Adicto**" y los valores inferiores como "**No Adicto**". Este umbral se aplicó tanto a los valores reales como a las predicciones continuas del modelo **MLPRegressor**, lo que permitió construir una matriz de confusión y calcular métricas de clasificación estándar.

Figura 5. Matriz de confusión del modelo MLP ($\text{Adicto} \geq 6.0$).



Las métricas de clasificación obtenidas sobre el conjunto de prueba (600 registros) fueron las siguientes:


- **Exactitud (Accuracy):** 0.983
- **Precisión (Precision):** 0.993

- **Sensibilidad (Recall):** 0.989
- **F1-Score:** 0.991
- **AUC-ROC:** 0.998

El reporte de clasificación detallado muestra que el modelo identifica correctamente al 99 % de los adolescentes con adicción ($Recall = 0.99$ para la clase "Adicto"), mientras que para la clase minoritaria "No Adicto" (39 casos de 600) se obtuvo una precisión de 0.85 y un recall de 0.90. Esta diferencia es consistente con el desbalance de clases observado en la Figura 2, donde más del 50 % de los registros corresponde al nivel máximo de adicción: al haber muchos menos ejemplos de la clase "No Adicto", el modelo dispone de menos información para aprender sus patrones, lo que se traduce en un desempeño ligeramente inferior para esa clase específica, aunque sigue siendo satisfactorio.

Adicionalmente, se evaluó cómo varían las métricas de clasificación al modificar el umbral de decisión entre 3.0 y 8.0.

Figura 6. Métricas de clasificación en función del umbral de decisión.



Este análisis de sensibilidad muestra que las métricas de clasificación son altas y muy estables para umbrales entre 3.0 y 5.5 (todas por encima de 0.995), pero presentan una caída y mayor oscilación a partir de un umbral de 6.0, especialmente en *Accuracy* y *Recall*, que llegan a descender hasta valores cercanos a 0.978–0.980 en el umbral de 8.0. Esta pérdida de estabilidad no se debe a que los niveles altos de adicción sean intrínsecamente más difíciles de predecir, sino al fuerte desbalance de clases descrito previamente: al desplazar el umbral hacia valores más altos, la clase "No Adicto" incorpora progresivamente casos de adicción moderada que antes se

agrupaban con la clase "Adicto", generando una frontera de decisión menos nítida y con menor cantidad de ejemplos de entrenamiento en esa región del espacio de salida. En consecuencia, pequeñas variaciones en las predicciones continuas del MLP se traducen en errores de clasificación más frecuentes conforme el umbral se acerca a los extremos de la distribución de **Addiction_Level**. Este comportamiento respalda la elección del umbral de 6.0, situado en el límite superior de la región más estable, y sugiere que umbrales más altos deberían interpretarse con mayor cautela si se utilizaran en una futura versión del sistema.

5.2 Comparación con un modelo de Regresión Lineal


Con el propósito de contextualizar el desempeño del modelo **MLPRegressor** y evaluar si la complejidad adicional de una red neuronal se traduce en una mejora real frente a un enfoque más simple, se entrenó un modelo de **Regresión Lineal Múltiple** como línea base (*baseline*). A diferencia del MLP, las variables numéricas no fueron estandarizadas en este caso, con el fin de que los coeficientes resultantes pudieran interpretarse directamente en las unidades originales de cada variable.

El modelo de Regresión Lineal obtuvo los siguientes resultados sobre el conjunto de prueba, tras recortar las predicciones al rango válido de 0 a 10:

- **Coefficiente de determinación (R^2):** 0.826
- **Error Absoluto Medio (MAE):** 0.472

Al comparar estos resultados con los obtenidos por el MLP ($R^2 = 0.987$, MAE = 0.146), se observa que la red neuronal logra un ajuste considerablemente superior, reduciendo el error absoluto medio a menos de un tercio del obtenido por la Regresión Lineal. Esto sugiere que, si bien existen relaciones lineales fuertes entre algunas variables y el nivel de adicción, también hay componentes no lineales e interacciones entre variables que el MLP logra capturar y que un modelo lineal simple no puede representar.

Figura 7. Variables más influyentes según los coeficientes de la Regresión Lineal.



A pesar de su menor desempeño predictivo, el modelo de Regresión Lineal aporta un valor complementario importante: la interpretabilidad directa de sus coeficientes. Las variables con mayor efecto positivo sobre el nivel de adicción fueron **Daily_Usage_Hours** (coeficiente ≈ 0.50), **Time_on_Gaming** (≈ 0.49) y **Time_on_Social_Media** (≈ 0.48), lo que indica que, en promedio y manteniendo las demás variables constantes, cada hora adicional dedicada a estas actividades incrementa el nivel de adicción estimado en aproximadamente medio punto en la escala de 0 a 10. En sentido contrario, **Sleep_Hours** presentó el efecto negativo más fuerte (coeficiente ≈ -0.25), confirmando que un mayor número de horas de sueño se asocia con una reducción del nivel de adicción.

Estos resultados coinciden con las variables identificadas como más relevantes en el análisis de correlación de Pearson (Figura 1) y en los diagramas de caja (Figura 3), lo que aporta consistencia metodológica al estudio: tanto el análisis exploratorio, como el modelo lineal interpretable y el modelo MLP de mayor desempeño, coinciden en señalar el tiempo de uso del teléfono (general, en redes sociales y en videojuegos) y las horas de sueño como los factores más determinantes del nivel de adicción. En conjunto, la comparación entre ambos modelos permite concluir que, si bien la Regresión Lineal ofrece una explicación transparente y directa de los factores asociados a la adicción, el MLP resulta más adecuado como motor de predicción del sistema por su mayor precisión, sin perder de vista que ambos enfoques son complementarios: uno para explicar y otro para predecir.

6. Consideraciones éticas

El uso de Inteligencia Artificial para estimar el nivel de adicción al teléfono inteligente en adolescentes, una población menor de edad y en muchos casos vulnerable, exige una reflexión ética explícita, más allá del desempeño técnico del modelo.

Naturaleza de la predicción y límites del sistema. Es importante precisar que el modelo desarrollado no constituye un diagnóstico clínico ni una herramienta de evaluación psicológica validada. **Addiction_Level** es una variable derivada de una encuesta autoadministrada (Kaggle, 2024), y las estimaciones del MLP reflejan patrones estadísticos aprendidos de esos datos, no un juicio clínico emitido por un profesional de la salud mental. Presentar la salida del modelo como un "diagnóstico" sería una representación engañosa de sus capacidades y podría inducir a error tanto a padres y educadores como a los propios adolescentes. Por ello, la interfaz y cualquier comunicación de resultados deben enmarcar la predicción como una **estimación orientativa de riesgo conductual**, y no como una conclusión médica o psicológica definitiva, dejando explícito que cualquier sospecha de adicción debe confirmarse mediante evaluación de un profesional cualificado.

Privacidad y protección de datos de menores. El conjunto de datos utilizado incluye información sensible sobre salud mental (ansiedad, depresión, autoestima) y hábitos de menores de edad. Aunque el dataset público empleado en este trabajo se encuentra anonimizado, cualquier despliegue del sistema con datos reales debería cumplir con marcos normativos de protección de datos de menores (p. ej., consentimiento parental, minimización de datos y almacenamiento seguro), y contemplar quién tiene acceso a los resultados individuales y con qué propósito.

Sesgos y representatividad del conjunto de datos. El modelo fue entrenado con una única muestra de 3,000 adolescentes de un rango etario y contexto geográfico específicos, por lo que sus predicciones pueden no generalizar adecuadamente a poblaciones con características socioculturales, económicas o de acceso a tecnología distintas. Asimismo, el fuerte desbalance de clases identificado en la Figura 2 (más del 50 % de los registros en el nivel máximo de adicción) implica que el modelo tiene menos capacidad de aprendizaje sobre los casos de "No Adicto", lo que podría traducirse en una menor fiabilidad para adolescentes con perfiles de bajo riesgo si el sistema se usara en poblaciones con una distribución distinta a la del dataset de entrenamiento.

Riesgo de etiquetado y estigmatización. Clasificar a un adolescente como "Adicto" (Sección 5.1) conlleva el riesgo de generar etiquetas estigmatizantes si esta información se comunica sin el debido cuidado, o si se usa para tomar decisiones (académicas, familiares o de acceso a dispositivos) sin contexto adicional. Se recomienda que cualquier resultado del sistema

se presente acompañado de recomendaciones constructivas y nunca como una sentencia definitiva sobre la persona.

Supervisión humana y rol del sistema. En línea con lo señalado en la Sección 4, el sistema fue concebido como una **herramienta de apoyo** para padres, educadores y profesionales de la salud, no como un sustituto de su criterio. La decisión final sobre cómo actuar frente a una estimación de riesgo alto debe recaer siempre en personas capacitadas, manteniendo al ser humano en el centro del proceso de decisión ("human-in-the-loop").

Transparencia e interpretabilidad. La incorporación del modelo de Regresión Lineal (Sección 5.2) no solo cumple un propósito comparativo, sino también ético: permite explicar en términos comprensibles qué factores influyen en la predicción, lo cual es especialmente relevante cuando el sistema puede afectar decisiones sobre menores. Se recomienda que futuras versiones del aplicativo incorporen explicaciones similares junto a cada predicción del MLP, en lugar de presentar únicamente un valor numérico.

En conjunto, estas consideraciones no invalidan el valor del sistema desarrollado, pero sí delimitan claramente su alcance: una herramienta de apoyo a la detección temprana, que debe usarse de manera responsable, con supervisión humana y sin sustituir la evaluación profesional.

7. Conclusiones

El presente trabajo permitió desarrollar e implementar un sistema de predicción del nivel de adicción al teléfono inteligente basado en una Red Neuronal Artificial de tipo *Multilayer Perceptron* (MLP), cumpliendo el objetivo general planteado. A partir de variables demográficas, conductuales y psicosociales, el modelo fue capaz de estimar el nivel de adicción de manera automatizada, constituyendo una herramienta de apoyo para la detección temprana de adolescentes con mayor riesgo de dependencia.

Los resultados obtenidos evidencian un desempeño satisfactorio del modelo sobre el conjunto de datos utilizado, alcanzando un **Coefficiente de Determinación (R^2) de 0.987** y un **Error Absoluto Medio (MAE) de 0.146**. Estas métricas indican que la arquitectura propuesta logra modelar adecuadamente la relación entre los hábitos de uso del teléfono inteligente y el nivel de adicción, obteniendo estimaciones consistentes dentro de las características del conjunto de datos analizado.

El análisis exploratorio permitió identificar que variables como **Daily_Usage_Hours**, **Time_on_Social_Media**, **Apps_Used_Daily**, **Phone_Checks_Per_Day** y **Sleep_Hours** constituyen los principales factores asociados al nivel de adicción. Estos resultados son consistentes con la literatura reciente, la cual señala que la intensidad de uso del teléfono inteligente representa uno de los predictores más relevantes del comportamiento adictivo en adolescentes.

Desde una perspectiva aplicada, el desarrollo de una interfaz web mediante **Gradio** demuestra que es posible integrar modelos de aprendizaje automático en herramientas accesibles para usuarios sin conocimientos técnicos, facilitando su utilización como apoyo en contextos educativos, familiares y de salud. No obstante, los resultados deben interpretarse considerando que el modelo fue entrenado con un único conjunto de datos obtenido mediante encuestas, por lo que su capacidad de generalización deberá validarse en otras poblaciones y contextos.

Como líneas de trabajo futuro, se propone ampliar el conjunto de datos con información proveniente de diferentes regiones y estudios longitudinales que permitan analizar la evolución de la adicción a lo largo del tiempo. Asimismo, sería de interés comparar el desempeño del MLP con otras arquitecturas de aprendizaje profundo, como redes neuronales más profundas o modelos recurrentes (LSTM) cuando se disponga de información temporal, así como incorporar técnicas de interpretabilidad que permitan comprender con mayor detalle la contribución de cada variable en las predicciones realizadas.

8. Referencias bibliográficas

- American Psychiatric Association. (2013). *Diagnostic and statistical manual of mental disorders* (5th ed.). American Psychiatric Publishing.
- Aguirre-Peñañiel, V., & Matar-Khalil, S. (2025). Mecanismos neurobiológicos del uso problemático del teléfono inteligente en adolescentes: Una revisión sistemática. *CES Psicología*, 18(3). <https://doi.org/10.21615/cesp.7758>
- Gradio. (2024). *Build and share machine learning apps*. <https://www.gradio.app/>
- Hidalgo-Fuentes, S., Martínez-Álvarez, I., Llamas-Salguero, F., Pineda-Zelaya, I. S., Merino-Soto, C., & Chans, G. M. (2025). Psychometric properties of the Smartphone Addiction Scale–Short Version (SAS-SV) in Honduran university students. *PLoS ONE*, 20(7), e0327226. <https://doi.org/10.1371/journal.pone.0327226>
- Kaggle. (2024). *Teen Phone Addiction and Lifestyle Survey*. <https://www.kaggle.com/datasets/khushikyad001/teen-phone-addiction-and-lifestyle-survey>
- Kim, K., Yoon, Y., & Shin, S. (2024). Explainable prediction of problematic smartphone use among South Korea's children and adolescents using a machine learning approach. *International Journal of Medical Informatics*, 186, 105441. <https://doi.org/10.1016/j.ijmedinf.2024.105441>
- K. S., Basha, M. S. A. B., Sucharitha, M. M., & Ayesha, S. (2025). Screen time to severity: Machine learning models for teen smartphone dependency prediction. In *2025 IEEE 4th International Conference for Advancement in Technology (ICONAT)* (pp. 1–9). IEEE. <https://doi.org/10.1109/ICONAT66879.2025.11362619>
- Li, Z., Long, Q., Hao, M., Liu, L., Weng, Y., Yang, C., Wu, J., Huang, B., Qiu, J., Huang, Y., & Huang, G. (2025). Discovery of factors associated with smartphone addiction among high school adolescents: Using machine learning and network analysis. *Journal of Affective Disorders*, 392, 120096. <https://doi.org/10.1016/j.jad.2025.120096>
- Liu, S., Lin, Y., Hu, W., Meng, Y., & Liu, X. (2026). Mapping heterogeneous predictors of problematic smartphone use in Chinese adolescents: A machine learning approach with a nationally representative sample. *Journal of Affective Disorders*, 410, 122007. <https://doi.org/10.1016/j.jad.2026.122007>
- Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., Blondel, M., Prettenhofer, P., Weiss, R., Dubourg, V., Vanderplas, J., Passos, A., Cournapeau, D.,

Brucher, M., Perrot, M., & Duchesnay, É. (2011). Scikit-learn: Machine learning in Python. *Journal of Machine Learning Research*, 12, 2825–2830.

Pew Research Center. (2022). *Teens, Social Media and Technology 2022*.

<https://www.pewresearch.org/internet/2022/08/10/teens-social-media-and-technology-2022/>

Zhou, Y., Pei, C., Yin, H., Zhu, R., Yan, N., Wang, L., Zhang, X., Lan, T., Li, J., Zeng, L., & Huo, L. (2025). Predictors of smartphone addiction in adolescents with depression: Combining the machine learning and moderated mediation model approach. *Behaviour Research and Therapy*, 189, 104749. <https://doi.org/10.1016/j.brat.2025.104749>

9. Anexos

Anexo A: Repositorio del proyecto

GitHub: <https://github.com/almeida-aguilar/rna-prediccion-adiccion-teen>